

MMM 모델 설명서

입력 데이터부터 사전정보, 검증, 해석까지

브라우저 안에서 동작하는 empirical-Bayes MMM의 실무·기술 참고서입니다. 모델이 무엇을 계산하는지, 불확실성이 어디서 오는지, 실험과 유사 국가 근거가 어떻게 전달되는지, 어디까지 인과적으로 해석하면 안 되는지를 설명합니다.

Edition 1.0 / 2026-07-23

MMM methodology 1.1.0 / 한국어·영어 동등 기능판

처리 원칙: 업로드한 CSV는 브라우저 메모리에서만 처리되며 서버로 전송되지 않습니다.

목차

1. 이 모델이 하는 일과 하지 않는 일	5
1.1 한 문장 정의	5
1.2 답할 수 있는 질문	5
1.3 답하면 안 되는 질문	5
1.4 결과 사용 등급	5
2. 빠른 시작: 분석 전부터 발표까지	6
2.1 10단계 워크플로	6
2.2 최소 데이터량	6
2.3 실행 전 60초 점검	6
3. MMM CSV 입력 규격	7
3.1 한 행의 의미	7
3.2 필드 사전	7
3.3 다중 KPI 매핑	7
3.4 이름 매핑 규칙	8
3.5 플랫폼 분리	8
3.6 Long-format 입력	8
4. 일별 데이터의 주간 전처리	9
4.1 월요일 시작 주차	9
4.2 합계와 발생 여부의 차이	9
4.3 결측·중복·부분 주	9
5. 모델 구조	10
5.1 결과 방정식	10
5.2 비매체 성분	10
5.3 표준화와 원 단위 복원	10
5.4 공선성	10
6. Empirical-Bayes 추론 방식	11
6.1 조건부 Gaussian 분석 근사	11
6.2 기본 정규화와 calibrated prior	11
6.3 효과 확률과 90% 구간	11
6.4 속도와 정확도의 교환	11
7. 광고 잔효·포화·모델 평균	12
7.1 기하 adstock	12
7.2 Hill 포화	12
7.3 후보 생성과 대표 변환	12
7.4 profile 모델 평균	12
7.5 반응곡선과 정상상태	12

8. 실험 prior: On/Off와 Geo	13
8.1 왜 점추정 하나가 아니라 원자료인가	13
8.2 실험 유형 판별과 지원 입력	13
8.3 일별 원자료의 실험 주차 생성	13
8.4 On/Off 입력	14
8.5 Geo 입력	14
8.6 90% 신뢰구간이 prior 강도가 되는 법	15
8.7 동일 KPI-기간 재사용과 적용 전 확인	15
9. 유사 국가 prior	16
9.1 목적과 입력	16
9.2 두 단계 선택	16
9.3 반복 12주 검증	16
9.4 국가 간 전달 이질성	16
9.5 올바른 해석	17
10. 검증과 모델 건강지표	18
10.1 세 층의 검증	18
10.2 일반 OOS backtest	18
10.3 건강지표 읽기	18
10.4 예측 정확도와 인과 타당성은 다름	18
11. 결과 화면 해석	19
11.1 기본 기여분해	19
11.2 기여 크기 비중	19
11.3 채널 효과 카드	19
11.4 prior 토글	19
12. 반응곡선·예산 추천·미래예측	20
12.1 반응곡선	20
12.2 예산 추천	20
12.3 예산 액션 식별 게이트	20
12.4 미래예측	21
12.5 예측구간	21
13. KPI별 운영 방법	22
13.1 sticky 목표 전환	22
13.2 퍼널 해석	22
13.3 KPI prior 적용표	22
14. Google Meridian과의 비교	23
14.1 한눈에 보는 차이	23
14.2 일반적인 완전 Bayesian MMM과의 차이	23
14.3 반영한 Meridian 원칙	23
14.4 현재 반영하지 않은 기능	24

15. 정확도·인과·한계	25
15.1 가장 큰 오차 원인	25
15.2 양수 확률의 언어	25
15.3 prior 선택 편향	25
15.4 개인정보와 데이터 처리	25
16. 문제 해결	26
16.1 업로드와 매핑	26
16.2 모델	26
16.3 실험 prior	26
16.4 국가 prior	26
17. 발표·검토 체크리스트	28
17.1 데이터 승인	28
17.2 모델 승인	28
17.3 prior 승인	28
17.4 발표 문구 템플릿	28
18. 용어집	29
부록 A. 계산·화면 대응표	30
부록 B. 공식 참고자료	31

이 설명서 읽는 법

운영자는 1~4장과 10~12장부터, 분석·검토 담당자는 5~9장과 14~15장까지 읽으세요. 마지막 체크리스트는 대외 발표 전 승인 절차에 바로 쓸 수 있습니다.

1. 이 모델이 하는 일과 하지 않는 일

1.1 한 문장 정의

이 앱의 MMM은 주간 성과 변동을 자연수요·추세·계절·이벤트·매체 기여로 나누고, 광고의 잔효와 포화를 고려해 채널별 효과의 방향·범위·반응곡선을 추정하는 클라이언트 사이드 분석 모델입니다.

핵심 결론

이 모델은 Meridian의 아이디어를 일부 차용했지만 Meridian 자체가 아닙니다. NUTS/MCMC를 돌리는 완전 계층형 모델이 아니라, 잔차분산을 plug-in 추정하고 정규 prior와 약한 ridge 정규화를 결합한 empirical-Bayes 조건부 Gaussian 근사입니다.

1.2 답할 수 있는 질문

- 같은 기간에 어떤 채널이 KPI 변동과 양의 관계를 보였는가? 효과의 양수 확률과 90% 구간은 얼마나 안정적인가?
- 현재 집행 수준이 반응곡선의 어느 위치에 있으며, 추가 예산의 한계효과가 얼마나 남았는가?
- 실험 또는 유사 국가 근거를 반영했을 때 결론이 얼마나 바뀌며, 각 근거의 전용 검증은 통과하는가?
- 추세·계절·이벤트를 분리한 뒤 주차별 성과를 어떤 요인이 설명했는가?
- 다섯 KPI 중 동일한 매체 입력에 대해 목표만 바꿨을 때 결론이 어떻게 달라지는가?

1.3 답하면 안 되는 질문

- 관측 데이터만으로 특정 채널의 순수 증분효과를 확정하는 것. 강한 공선성이나 동시 집행이 있으면 식별이 불가능할 수 있습니다.
- 양수 확률이 낮다는 이유만으로 효과가 0이라고 단정하는 것. 이는 효과 없음이 아니라 증거 부족일 수 있습니다.
- 반응곡선 추천을 계약·재고·입찰 변화가 없는 확정 예산안으로 사용하는 것.
- 다른 정의·통화·전환창을 쓰는 국가의 계수를 이름만 같다는 이유로 그대로 이전하는 것.
- 모델 적합도 R2가 높다는 이유로 인과적으로 정확하다고 판단하는 것.

1.4 결과 사용 등급

등급	사용 조건	허용되는 의사결정	필수 문구
탐색	관측 데이터만, 식별 경고 존재	추가 실험 우선순위·데이터 개선	연관 기반 잠정 결론
근거 보정	실험/국가 prior 적용, 근거별 진단 통과	범위형 예산 시나리오·채널 비교	prior 가정과 검증 결과 공개
의사결정 보조	실험과 MMM 방향 일치, base OOS·건강지표 양호	점진적 예산 변경과 후속 측정	인과 확정이 아닌 보조 근거

2. 빠른 시작: 분석 전부터 발표까지

2.1 10단계 워크플로

- 1 날짜, 채널 spend, KPI, 0/1 이벤트·구조변화 열을 같은 CSV에 준비합니다.
- 2 일별 파일을 그대로 업로드합니다. 앱이 월요일 시작 주차로 묶습니다.
- 3 총유입·가입·재유입·매출·구매자 중 보유한 KPI를 매핑합니다.
- 4 광고 열은 Performance 또는 Brand로 분류하고 0/1 이벤트·구조변화 열을 확인합니다.
- 5 분석하기를 눌러 기본 모델을 먼저 실행합니다.
- 6 예측 정확도, 구간 커버리지, 잔차 자기상관, 음수 자연수요를 확인합니다.
- 7 실험 데이터가 있으면 Auto 판별 또는 사용자가 강제 선택한 On/Off-Geo 유형으로 prior를 생성합니다.
- 8 참고 국가 데이터가 있으면 후보 국가와 추천 조합의 12주 반복 검증을 확인합니다.
- 9 결론 화면에서 prior 적용/제거를 전환해 민감도를 비교합니다.
- 10 대외 발표에는 데이터 범위·모델 버전·prior 출처·검증·한계를 함께 적습니다.

2.2 최소 데이터량

상태	권장 주수	판단
실무 권장	104주 이상	2년 계절·집행 변동과 반복 검증에 가장 유리
분석 가능	52~103주	모델은 실행하되 예산 액션은 식별 게이트를 통과해야 함
앱 low-info	52주 미만	효과 탐색은 가능해도 예산 추천을 차단
매우 짧음	24주 미만	시계열 분해·포화·홀드아웃을 함께 식별하기 어려움

더 많은 행이 항상 더 좋은 것은 아님

같은 예산 패턴이 오래 반복된 데이터보다, 채널별 증감 시점이 구분되고 지원되는 0/1 이벤트·구조변화가 잘 기록된 데이터가 식별에 더 유리합니다.

2.3 실행 전 60초 점검

- KPI는 주차별 합산 가능한 숫자인가? 누적값·비율·코호트 D7 같은 창 지표를 캘린더 주차 KPI와 섞지 않았는가?
- spend와 KPI의 국가·통화·시간대·전환창이 일치하는가?
- 채널명이 분석 파일·실험 prior·국가 prior에서 정확히 같은가?
- 프로모션·장애·명절처럼 앱이 지원하는 요인은 정확한 0/1 이벤트 또는 구조변화 step으로 기록했는가? 연속형 가격·경쟁 변수는 직접 매핑되지 않는 한계도 공개했는가?
- 채널이 항상 같이 켜지고 꺼지는 완전 공선 패턴은 없는가?

3. MMM CSV 입력 규격

3.1 한 행의 의미

한 행은 일자 또는 주차입니다. 날짜가 일별이면 앱이 월요일을 시작으로 하는 주차로 자동 집계합니다. 이미 주차별 파일이라면 주차 식별 열을 그대로 사용합니다. 시간 열이 전혀 없으면 '이미 주별 1행이며 오래된 주→최신 주로 정렬됨'을 사용자가 명시적으로 확인해야 행 순서 t를 쓸 수 있습니다. 같은 파일 안에서 일별·주별 행을 섞지 마세요.

3.2 필드 사전

역할	예시 헤더	필수	집계	주의
날짜/주차	date 또는 week	둘 중 1개 또는 행순서 확인	일자는 월요일 주차로 변환	ISO 날짜/ISO week 권장
국가	country	기본 선택 / 국가 prior 필수	국가별 분리	타킷은 정확히 1개 코드
플랫폼/세그먼트	platform	선택	값별 분리 또는 Total 합산	Android/iOS 정의 고정
매체비	meta_spend, search_spend	1개 이상	주간 합계	음수 금지, 통화 일치
총유입	traffic, sessions	Y 선택	주간 합계	가입+재유입 합성도 가능
가입	registrations	Y 선택	주간 합계	정의·중복제거 기준 고정
재유입	reactivations	Y 선택	주간 합계	재가입/복귀 정의 고정
매출	revenue	Y 선택	주간 합계	통화와 환불 처리 고정
구매자	purchasers	Y 선택	주간 합계	주간 unique 기준 권장
이벤트/구조변화	holiday, promo, outage	선택	주간 발생 여부/step	숫자 또는 인식 가능한 이진 0/1만 허용

숫자는 천 단위 쉼표·과학 표기와 명시적 규모 접미사(K/M/B, 천/만/백만/억)를 해석합니다. 예를 들어 1.2M은 1,200,000, 3억원은 300,000,000입니다. 1.2MB처럼 의미가 모호한 접미사는 숫자 1.2로 조용히 축소하지 않고 오류로 처리합니다. 날짜 열의 5자리 Excel serial은 메인 MMM·실험·국가 prior 모두 같은 1900 날짜 체계의 UTC 일자로 변환합니다. 플랫폼/세그먼트가 행으로 나뉜 CSV는 같은 주의 행을 합쳐야 하므로 행순서 확인만으로 대신할 수 없고 날짜 또는 주차 열이 반드시 필요합니다.

3.3 다중 KPI 매핑

총유입·가입·재유입·매출·구매자 중 실제 열이 있는 목표만 활성화됩니다. 분석 후 상단 sticky 목표 선택기에서 KPI를 바꾸면 같은 매체·이벤트·구조변화 구조로 각 목표 결과를 탐색할 수 있습니다. 총유입 열이 없고 가입과 재유입이 모두 있으면 두 열의 합을 총유입 슬롯으로 사용할 수 있지만, 같은 값을 RR/Total 같은 여섯 번째 중복 목표로 다시 노출하지 않습니다.

Y 개수가 다르면

타킷 MMM에는 있지만 실험 또는 국가 prior 파일에 매핑되지 않은 KPI에는 prior가 적용되지 않습니다. 해당 목표는 관측 데이터 기반 기본 모델로 남으며, 화면에 미적용 상태를 표시해야 합니다.

3.4 이름 매핑 규칙

- 타깃 파일의 meta_spend를 보정하려면 prior 파일에도 같은 채널을 meta_spend로 매핑해야 합니다.
- 대소문자·공백·접두어가 다르면 자동 연결을 신뢰하지 말고 매핑 화면에서 확인합니다. 한글 등 Unicode 헤더도 이름 자체로 안정적인 내부 key를 만들지만, 의미가 같은지는 사람이 확인해야 합니다.
- Y도 같은 비즈니스 정의로 연결해야 합니다. 단지 헤더가 같다고 단위·전환창이 같다고 검증되는 것은 아닙니다.
- 국가 코드와 통화가 다르면 계수 단위가 달라지므로 환율·KPI 스케일을 먼저 통일합니다.

3.5 플랫폼 분리

platform 열 또는 Android/iOS 태그 열을 매핑하면 Total과 플랫폼별 결과를 전환할 수 있습니다. Total은 같은 주의 플랫폼 KPI:spend를 합산하고, Android와 iOS는 각자 별도 Y 모델을 적합합니다. 두 플랫폼 차이가 커도 한쪽 계수를 다른 쪽에서 자동 참조하거나 평균내지 않습니다. 차이가 실제 유저 구성·가격·측정창 때문인지 확인하고 별도 결론으로 보고 하세요.

실험 prior도 같은 플랫폼 grain만 사용

Android 또는 iOS 결과에 prior를 붙이려면 실험 파일에 같은 platform 행이 있거나, 그 플랫폼 태그가 붙은 Y가 명시적으로 매핑되어야 합니다. Total은 매핑된 모든 플랫폼 Y를 합산하지만, 구성 Y 하나라도 빠진 행은 제외합니다. Total이나 다른 OS 값을 선택 플랫폼에 대신 빌려 쓰지 않습니다.

3.6 Long-format 입력

week/date | channel | spend | Y 형태도 지원합니다. 같은 기간·세그먼트의 채널별 행에는 전체 Y와 이벤트/step 값을 똑같이 반복하고, spend만 채널별 값으로 넣습니다. 앱은 spend를 wide 채널 열로 pivot하지만 반복 Y를 더하지 않습니다. 빈 시간·빈 채널 행, 서로 다른 반복 Y/이벤트 값은 조용히 버리거나 첫 값을 택하지 않고 분석을 차단합니다. 따라서 원자료 행 순서를 뒤집어도 같은 결과 또는 같은 차단 진단이 나옵니다.

4. 일별 데이터의 주간 전처리

4.1 월요일 시작 주차

각 날짜는 그 날짜가 포함된 월요일 시작 주차에 지정됩니다. 일요일까지 한 주로 묶은 뒤 시간순으로 정렬합니다. 이 방식은 일별 변동을 광고 잔효보다 짧은 노이즈로 과대해석하는 것을 줄이고, MMM 입력 단위를 일관되게 만듭니다.

```
week_start(d) = Monday of the calendar week containing date d
weekly_spend[w] = sum(spend[d]) for d in week w
weekly_kpi[w] = sum(kpi[d]) for d in week w
weekly_event[w] = 1 if any event[d] = 1 in week w, else 0
```

4.2 합계와 발생 여부의 차이

광고비·유입·가입·재유입·매출·구매자는 흐름값이므로 합계가 기본입니다. 명절·프로모션·장애처럼 0/1 이벤트는 7일 합계가 아니라 그 주 발생 여부로 처리합니다. 이벤트와 구조변화 열은 숫자 또는 앱이 인식하는 이진값으로 정확히 0/1이어야 하며, 공란·다른 숫자를 0으로 간주하지 않고 분석을 차단합니다. 이벤트가 3일 있었다고 강도가 자동으로 3배가 되는 것을 막기 위해서입니다.

4.3 결측·중복·부분 주

문제	앱 처리	사용자 조치
invalid/빈 날짜	행 제외 후 분석 차단 이슈	원본 날짜 수정
같은 날짜/주차 중복	동일 platform grain이면 분석 차단	원천 단위 확인 후 중복 제거
빠진 주차	calendar gap 분석 차단	실제 KPI·spend 주차 행 추가
내부 partial week	최빈 5/7일 cadence보다 적으면 차단	빠진 일자 복구
첫/마지막 partial	자동 제외 + 경고	완전 주만 쓸지 확인
매체비/KPI 공란	0으로 합산하지 않고 선택 Y/채널 분석 차단	실제 무집행만 0, 수집 실패는 복구
음수 매체비	분석 차단	환불·보정 행을 원천 정의에 맞게 정리
이벤트/step이 0/1 아님	분석 차단	정확한 이진값으로 수정; 공란을 0으로 대체하지 않음
비율 KPI	자동 보정 안 함	분자·분모 원자료로 재정의

주간화가 해결하지 못하는 것

주간 집계는 공선성·누락된 교란요인·측정 정의 불일치를 해결하지 않습니다. 단지 시간 단위를 맞추고 일별 노이즈를 줄이는 전처리입니다. 이 앱은 임의의 연속형 가격·경쟁 통제열을 직접 매핑하지 않습니다. 의미 있는 변화 시점은 근거가 있을 때만 0/1 이벤트 또는 step으로 표현하고, 그렇지 못한 요인은 모델 한계로 공개하세요.

5. 모델 구조

5.1 결과 방정식

각 KPI는 별도 모델로 적합합니다. 자연수요 수준과 장기 추세, 계절성, 이벤트·구조변화, 변환된 매체 입력을 더해 주간 KPI를 설명합니다.

```
y[t] = intercept + trend[t] + seasonality[t] + events[t]
      + sum_m beta[m] * Hill(Adstock(spend[m,t])) + error[t]
error[t] ~ Normal(0, sigma^2)
```

5.2 비매체 성분

성분	역할	해석 주의
Trend	절편과 장기 방향	브랜드 자연수요 전체와 동일한 개념은 아님
Seasonality	설정된 주기의 sin/cos 반복 패턴	불규칙 이벤트는 별도 열 필요
Holidays & Events	명절·프로모션·장애 등 알려진 충격	미래 발생을 모르면 예측에 0 또는 시나리오 입력
Regime change	측정·상품·정책 변화의 단계 효과	광고 효과와 중복 설명하지 않게 시점 근거 필요
Performance / Brand	매핑된 채널의 주차별 기여	그룹 합은 보고 단위이며 채널 식별은 별도 확인

기본 계절성 grid는 연간 52.18주와 분기 13.04주이며, 각 주기마다 sin/cos 한 쌍을 사용합니다. 별도 월·요일·국가 달력 효과를 자동 생성하지 않습니다.

자동 달력·임의 step 없음

모델은 '한국 명절 주차'를 국가 이름으로 하드코딩하지 않으며 42주·55주 같은 임의의 시점 step도 만들지 않습니다. 명절·프로모션·측정 변경은 사용자가 매핑한 이벤트/step 열만 사용합니다. 공선성이 높은 step도 조용히 자동 삭제하지 않고 진단으로 알려므로, 유지·통합·제거는 실제 변경 근거를 보고 결정해야 합니다.

5.3 표준화와 원 단위 복원

수치 안정성을 위해 회귀 입력은 열별 평균을 빼고 표준편차로 나눠 적합합니다. 화면의 계수·기여·prior는 다시 원래 변환 feature 단위와 KPI 단위로 환산합니다. KPI를 원에서 천원으로 바꾸더라도 같은 불확실성 구조가 유지되도록 calibrated prior precision도 스케일에 맞게 변환합니다.

```
z[j,t] = (x[j,t] - mean(x[j])) / sd(x[j])
beta_raw[j] = beta_standardized[j] / sd(x[j])
Var(beta_standardized prior) = Var(beta_raw prior) * sd(x[j])^2
```

5.4 공선성

채널 두 개가 거의 같은 주차에 같은 비율로 움직이면 합산 효과는 설명해도 개별 효과는 구분하기 어렵습니다. prior는 정보를 추가할 수 있지만, 잘못된 prior로 식별 불가능을 가리는 용도로 쓰면 안 됩니다. 이런 경우 채널 통합, 추가 기간 확보, geo/holdout 실험이 우선입니다.

6. Empirical-Bayes 추론 방식

6.1 조건부 Gaussian 분석 근사

이 앱은 수천 번의 posterior 샘플을 생성하지 않습니다. 잔차분산 σ^2 를 데이터에서 plug-in 추정하고, 그 값에 조건부로 선형 Gaussian likelihood와 정규 prior/약한 ridge penalty를 결합해 계수 평균과 공분산을 행렬 계산으로 구합니다. σ^2 까지 적분한 Student-t posterior나 완전 계층형 joint posterior가 아니라 empirical-Bayes 분석 근사입니다. 같은 입력은 항상 같은 결과를 내며 브라우저에서 빠르게 실행됩니다.

```
Likelihood: y | beta ~ Normal(X beta, sigma^2 I)
Calibrated prior: beta[j] ~ Normal(mu[j], v[j])
Posterior precision = X'X / sigma^2 + prior_precision
Posterior mean = inverse(Posterior precision) * (X'y / sigma^2 + prior_precision * mu)
```

6.2 기본 정규화와 calibrated prior

외부 근거가 없는 계수에는 과적합을 줄이는 약한 ridge penalty가 적용됩니다. 실험·국가 prior가 있는 매체 계수에는 실제 Normal(mean, variance)의 precision이 적용됩니다. 구현은 잔차분산을 plug-in 추정하고 prior penalty를 잔차 스케일에 맞춰 고정점 갱신합니다. 이 절차는 KPI 단위 변경에 대한 prior 상대 강도를 보정하지만, σ^2 자체의 posterior 불확실성을 적분하지는 않습니다.

6.3 효과 확률과 90% 구간

prior로 대표 변환이 고정된 채널은 조건부 계수 평균·표준편차로 양수 확률과 90% 구간을 계산합니다. prior가 없는 채널에서 변환 후보를 평균할 때는 후보별 양수 확률을 BIC 가중 평균하고, 효과 90% 구간은 가중 Gaussian mixture의 누적분포를 직접 뒤집어 5%·95% 분위수를 찾습니다. 따라서 profile 구간은 혼합 평균·분산으로 만든 정규근사가 아니라 후보가 갈릴 때 비대칭·다봉성까지 반영한 mixture CDF 분위수입니다.

```
F_mix(x) = sum_k weight[k] * Phi((x - mean[k]) / sd[k])
CI90 = [inverse_F_mix(0.05), inverse_F_mix(0.95)]
```

샘플링 진단은 표시하지 않음

MCMC를 실행하지 않으므로 R-hat, effective sample size, trace plot은 계산할 수 없습니다. 해당 수치를 흉내 내지 않고 '해당 없음'으로 처리합니다.

6.4 속도와 정확도의 교환

장점	대가
브라우저에서 빠르고 결정론적	비선형·계층 posterior 전체 모양을 직접 샘플링하지 않음
prior 평균·분산이 명시적	모델 오지정이나 공선성을 posterior가 자동 해결하지 않음
다중 KPI 전환이 용이	각 KPI가 별도 모델이며 KPI 간 공분산을 공동 추정하지 않음
서버 전송 불필요	대규모 geo 채널·수천 후보는 브라우저 한계가 있음

7. 광고 잔효·포화·모델 평균

7.1 기하 adstock

광고 효과가 집행 주에 끝나지 않는다고 보고 이전 주의 노출 상태를 α 비율로 다음 주에 넘깁니다. α 가 클수록 잔효가 오래갑니다. Geo 실험 원자료는 지역별로 상태를 따로 계산해 한 지역의 마지막 주 잔효가 다음 지역으로 흘러가지 않게 합니다.

```
adstock[t] = spend[t] + alpha * adstock[t-1], 0 <= alpha < 1
```

7.2 Hill 포화

반포화점 ec 는 반응이 최대값의 절반에 도달하는 adstock 수준이고, $slope$ 는 곡선 굴곡을 정합니다. 지출이 커질수록 추가 1원의 효과가 줄어드는 패턴을 표현합니다.

```
hill(a; ec, slope) = a^slope / (a^slope + ec^slope)
```

7.3 후보 생성과 대표 변환

각 채널에서 $\alpha \times ec \times slope$ 후보를 비교합니다. 고정 grid는 $\alpha = 0.0, 0.1, \dots, 0.8$; ec = 해당 채널의 양수 adstock 분포 40%·60%·80% 분위수; $slope = 0.6, 0.8, 1.0, 1.4$ 입니다. 먼저 비매체 요인을 제거한 잔차와의 관계 크기로 대표 변환을 고르고, 관계의 부호는 이후 계수 근사가 판단합니다. 이 대표 변환은 주차별 기본 기여분해와 미래 예측에 사용됩니다. profile fit 예산은 외부 prior가 없으면 채널당 최대 48·전체 480, prior가 하나라도 있으면 전체 240이며, profile이 필요한 no-prior 채널 수로 균등 배분합니다.

7.4 profile 모델 평균

prior가 없는 채널의 효과 확률·구간·반응곡선·예산 추천은 대표 변환 하나만 믿지 않습니다. 한 채널의 후보를 바꾸고 다른 채널은 대표 변환에 고정한 profile 모델을 각각 재적합한 뒤 BIC 차이로 가중합니다. On/Off 실험 prior는 타깃 대표 $\alpha \cdot ec \cdot slope$ 로 처리강도를 변환하고, Geo prior는 선형 adstock ratio를 겹치는 타깃 기간의 Hill 미분으로 같은 계수 단위에 정렬합니다. 국가 prior는 각 참고국을 타깃의 같은 $\alpha \cdot ec \cdot slope$ 로 다시 적합합니다. prior가 있는 채널은 이 정렬된 대표 변환에 고정하며 다른 변환에 같은 prior 숫자를 재사용하지 않습니다.

```
weight[k] proportional to exp(-0.5 * (BIC[k] - min(BIC)))
mean_mix = sum_k weight[k] * mean[k]
var_mix = sum_k weight[k] * (sd[k]^2 + mean[k]^2) - mean_mix^2
effective_candidates = 1 / sum_k weight[k]^2
```

중요한 범위

이는 모든 채널 후보의 데카르트 곱을 동시에 평균하는 joint Bayesian model average가 아닙니다. 채널별 one-at-a-time profile 평균입니다. 따라서 채널 간 변환 불확실성의 모든 상호작용을 포착하지 않습니다.

7.5 반응곡선과 정상상태

반응곡선의 x축은 한 주만 집행한 총격이 아니라 지속 가능한 주간 spend 수준입니다. 따라서 각 후보에서 $\text{steady-state adstock} = \text{spend} / (1 - \alpha)$ 를 사용합니다. α 가 바뀌면 같은 주간 spend의 누적 노출과 한계효과도 달라집니다.

8. 실험 prior: On/Off와 Geo

8.1 왜 점추정 하나가 아니라 원자료인가

실험 원자료를 제공하면 효과 크기뿐 아니라 불확실성도 같은 설계에서 추정할 수 있습니다. On/Off는 KPI 처리효과를 타깃 $\alpha\text{-ec}\cdot\text{slope}$ 로 만든 transformed exposure 처리효과로 나눕니다. Geo는 비선형 Hill을 지역별로 적용한 뒤 더하지 않고, 먼저 지역별 선형 adstock 처리효과로 나눈 뒤 실험과 타깃 기간이 겹치는 national adstock 운용점의 Hill 미분으로 타깃 계수 단위에 옮깁니다. 같은 행·같은 설계의 cross-equation covariance, delta method, Fieller ratio 구간과 jackknife로 오차를 전파합니다.

```
On/Off prior_mean = effect_KPI / effect_Hill(adstock)
Geo r_A = DiD_effect_KPI / DiD_effect_geo_adstock
Geo prior_mean = r_A / Hill_derivative(target_overlap_adstock)
Var(y/x) approximately Var(y)/x^2 + y^2 Var(x)/x^4
- 2*y*Cov(y,x)/x^3
require a bounded two-sided 90% Fieller ratio interval
prior_variance = max(delta_variance * inflation^2, Fieller_equivalent_variance,
jackknife_SE^2 * inflation^2)
prior_precision = 1 / prior_variance
```

8.2 실험 유형 판별과 지원 입력

업로드 직후 기본값은 Auto입니다. Auto는 type 열이 있으면 그 값을 가장 먼저 사용하고, type이 없으면 Geo wide/long 스키마를 확인한 뒤 나머지를 On/Off로 판별합니다. type은 Geo·OnOff처럼 파일 전체에서 하나의 해석 가능한 값이어야 합니다. 자동 판별이 데이터 의도와 다르면 화면의 실험 유형 선택기에서 On/Off 또는 Geo를 강제할 수 있으며, 강제 선택이 type 열과 자동 스키마 판정보다 우선합니다. 화면에는 판별된 유형과 판별 근거를 함께 표시합니다.

형태	필수 열	정규화
On/Off wide	type(선택), time, state, KPI, 대상 channel spend	주차별 1행으로 사용
Geo long	type(선택), time, period, geo, arm, KPI, 대상 channel spend	geo x 주차 패넬로 사용
Geo wide	type(선택), time, period, target_geo, control_geo, target_/control_ KPI:spend 쌍	각 행을 treatment:control 두 geo 행으로 변환
매체 long	time, channel, spend와 위 설계 열·반복 KPI	메인 MMM과 같은 채널 헤더의 spend wide 열로 pivot

템플릿의 헤더를 실제 매핑명으로 변경

화면에서 On/Off, Geo wide, Geo long 예시 CSV를 내려받을 수 있습니다. 예시의 registrations와 meta_spend는 메인 MMM에 매핑한 실제 Y·채널 헤더와 정확히 같게 바꾸세요. 매체 long 파일의 channel 값도 같은 채널로 매핑될 수 있어야 하며, 같은 time:geo:platform에 반복된 KPI가 서로 다르면 첫 값을 임의 선택하지 않고 보류합니다.

8.3 일별 원자료의 실험 주차 생성

날짜가 파싱되는 일별 실험 파일은 geo가 있으면 geo x 월요일 시작 주차, geo가 없으면 월요일 시작 주차로 먼저 묶습니다. KPI와 대상 채널 spend는 주간 합산합니다. 잘못된 날짜 행은 제외하고, 같은 주 안에서 state:arm:period가 섞인 경계 주와 주 안 일부 행의 KPI 또는 spend가 결측인 주는 통째로 제외합니다. 관측된 주들의 최빈 cadence로 5일/7일을 판정해 첫·마지막 partial week는 제외하고, 내부 partial week나 빠진 주차·중복 주차가 있으면 adstock 시간을 압축하지 않도록 prior 생성을 보류합니다.

진단	화면/내보내기 의미
source rows	업로드한 원자료 행 수
usable weeks	주간화·검증을 통과해 prior 계산에 쓴 geo-week/주차 수
unparseable date rows	날짜 해석 실패로 제외된 행 수
mixed boundary weeks	한 주에 state/arm/period가 둘 이상이라 제외된 주 수
missing weeks	주 내 KPI/spend 일부 결측 때문에 제외된 주 수
partial/gap diagnostics	경계 partial 제외 수와 내부 partial 빠진 주차·중복 주차 차단 사유

제외는 보수적 식별 규칙

경계 주를 다수결로 ON 또는 POST에 억지 배정하지 않습니다. 원자료→사용 주차와 제외 사유를 함께 남겨 prior가 어떤 표본에서 계산됐는지 재현할 수 있게 합니다.

플랫폼별 prior는 선택한 플랫폼과 같은 platform 행 또는 Android/iOS 태그가 붙은 해당 Y만 사용합니다. Total은 매핑된 플랫폼 Y를 모두 합산하며, 구성 Y가 하나라도 결측인 행은 계산에서 제외합니다. Total이나 다른 OS의 결과를 선택 플랫폼 prior로 대체하지 않습니다.

8.4 On/Off 입력

입력	내용	예시
time	날짜 또는 주차	2026-01-05
state	ON/OFF 상태	on, off
channel spend	대상 채널 집행액	meta_spend
KPI	타겟과 같은 정의의 결과	registrations

ON-OFF-ON처럼 상태가 반복되는 기간 데이터가 필요합니다. prior 계산에는 검증을 통과한 주간 관측치가 최소 16개, ON-OFF 각각 최소 4주, 상태 전환 최소 2회가 필요합니다. ON 1주/OFF 15주나 단 한 번 컷다가 끝난 구간은 자동 prior가 되지 않습니다. spend만으로 상태를 찾을 때도 검증된 0만 OFF로 쓰며 결측을 0으로 바꾸지 않습니다. 시계열 오차에는 HAC 표준오차와 block jackknife를 사용하며, HAC 계산이 실패하면 일반 OLS 표준오차로 후퇴하지 않고 prior를 보류합니다. 이 변환기는 promo-outage 같은 추가 연속 통제열을 회귀에 넣지 않으므로 동시 충격은 별도로 공개하세요.

8.5 Geo 입력

입력	내용	예시
time	동일한 관측 주차	2026-W08
geo	지역 식별자	Seoul, Busan
arm	target/control	treatment, control
period	pre/post	pre, post
channel spend	지역별 대상 채널 집행	search_spend
KPI	지역별 결과	revenue

Geo prior에는 비교 가능한 날짜/주차 열, 검증된 geo-week 관측치 최소 16개, 최소 4개 geo, treatment와 control 각각 최소 2개 geo가 필요합니다. 각 geo의 arm은 전 기간 고정되어야 하고, 같은 주의 pre/post 상태는 모든 geo에서 같아야 하며, 모든 geo가 pre와 post를 모두 가져야 합니다. treatment/control x pre/post 네 셀 중 하나라도 없으면 보류합니다. 앱은 geo-주차 고정효과를 포함한 treatment x post DiD를 지역별 선형 adstock에 대해 추정합니다. cluster covariance가 실패하면 OLS SE로 후퇴하지 않고, 모든 geo 삭제 적합이 성공할 때만 LOCO를 인정합니다. 효과/처리강도 ratio의 양측 90% Fieller 구간이 bounded가 아니면 보류합니다. 실험과 타깃 MMM 주차가 최소 4주 겹쳐야 national HMM 미분 기준점을 만들 수 있으며, 겹침이 없거나 미분이 사실상 0이면 단위 정렬 실패로 보류합니다.

```
inflation = max(1, t_critical(0.90, df) / 1.645)
prior_variance = max(cluster_delta_variance * inflation^2, Fieller_equivalent_variance,
LOC0_SE^2 * inflation^2)
```

한 holdout에서 여러 spend가 함께 바뀌면

동일 파일에 spend 열이 여러 개면 앱은 실험 state/arm/period 대비로 충분히 변한 열을 먼저 찾습니다. 정확히 한 채널만 뚜렷하면 그 채널을 쓰고, 둘 이상이 함께 움직이면 총 결합효과는 보여도 채널별 효과를 분리할 수 없어 prior를 보류합니다. 선택된 채널도 transformed-exposure 효과가 0과 구분되지 않으면 ratio가 폭발할 수 있으므로 weak-intensity gate에서 보류합니다.

8.6 90% 신뢰구간이 prior 강도가 되는 법

현재 UI는 요약 CI 숫자만 받지 않고 기간 원자료에서 효과/처리강도 ratio의 delta 분산, 공분산, bounded 90% Fieller 구간과 jackknife를 직접 계산합니다. Fieller 구간이 unbounded/disjoint면 ratio prior를 만들지 않습니다. 유한하면 평균에서 더 먼 끝점의 폭을 1.645로 나눠 보수적인 대칭 Normal 분산 후보로 바꾸고, robust delta:jackknife와 비교해 가장 넓은 불확실성을 사용합니다. 구간이 넓을수록 precision이 낮아져 MMM 데이터가 prior를 쉽게 수정합니다. 임의의 강도 슬라이더는 없습니다.

8.7 동일 KPI·기간 재사용과 적용 전 확인

같은 결과를 prior와 likelihood에 두 번 넣지 않기

실험 주차와 메인 MMM 주차가 겹치는 사실만으로 자동 탈락하지는 않지만, 같은 모집단의 동일 KPI 값을 복제해 양쪽에 넣으면 독립 근거가 아닙니다. 앱은 national On/Off에서 비교 가능한 중첩 주가 4개 이상이고 그중 95% 이상이 메인 MMM의 같은 주 Y와 수치적으로 일치하면 재사용 패턴으로 보고 prior를 자동 보류합니다. 날짜형과 숫자형 인덱스처럼 두 시간축 자체를 비교할 수 없을 때도 중복 사용을 배제할 수 없으므로 On/Off prior를 보류합니다. 부분 기간 중첩과 Geo 근거는 중첩 주수·정확 일치 주수를 진단에 표시하므로, 별도 처리군/대조군 집계에서 얻은 근거인지 사용자가 확인해야 합니다.

- 실험의 KPI 정의·전환창·통화·대상 사용자가 MMM과 같은가?
- 실험 집행 강도가 MMM의 관측 범위 안에 있는가? 지나친 외삽은 아닌가?
- 동시에 바뀐 프로모션·가격·크리에이티브가 없는가?
- 실험 채널 헤더와 MMM 채널 매핑이 정확히 같은가?
- 실험 시기와 현재 시장 사이의 전달 불확실성을 설명했는가?

실험도 자동으로 완벽한 prior가 아님

Meridian 공식 가이드도 실험의 estimand·기간·모집단과 MMM 목표가 다를 수 있으므로 추가 전달 불확실성을 고려하라고 설명합니다. 좁은 실험 CI를 무비판적으로 전체 기간에 강제하지 마세요.

9. 유사 국가 prior

9.1 목적과 입력

타깃 국가 MMM 파일과 같은 포맷의 여러 참고 국가 데이터를 업로드해, 타깃 국가에 전달 가능한 채널 계수 근거를 찾습니다. 메인 MMM CSV에는 정확히 하나의 COUNTRY 값, 참고 CSV에는 국가 구분 COUNTRY 열이 있어야 하며 각 참고 국가는 최소 24개 유효 주간 행이 필요합니다. 타깃 국가를 확정할 수 없으면 자기 데이터가 prior로 재유입되는 self-reference를 막기 위해 국가 prior 전체를 보류합니다. 매체와 KPI는 이름뿐 아니라 정의·단위까지 사용자가 확인해야 합니다.

9.2 두 단계 선택

- 1차 적격성: 데이터 길이·겹치는 채널·KPI·시간축 정합과 모델 적합 가능성을 확인하고 최대 12개 참고국을 1차 적합합니다. 각 적격 국가는 개별 카드로 노출합니다.
- 공통 비교: 최대 12개 국가와 이후 조합을 똑같은 비중복 rolling-origin folds에서 평가합니다. 단일 holdout보다 안정적이지만, 같은 folds를 shortlist와 조합 선택에 재사용하므로 선택 편향을 제거한 독립 OOS는 아닙니다.
- 조합 탐색: 동일 folds 점수가 좋은 상위 4개 국가만 shortlist한 뒤 최대 3개 국가 조합, 최대 24개 세트를 비교합니다.
- 선택: 평균 오차뿐 아니라 fold 불안정성·2% 최소 개선·fold 승률·딱지은 fold 개선이 그 개선 잡음의 1 SE를 넘는지·국가 수 복잡도와 one-standard-error 단순성 규칙을 반영해 한 조합을 추천합니다.
- 기본 모델이 더 낫거나 차이가 불안정하면 prior 미적용을 선택합니다.

9.3 반복 12주 검증

기본 설정은 12주 창을 최근 시점부터 과거로 12주씩 이동해 서로 겹치지 않는 최대 3개 fold를 만듭니다. 각 fold는 최소 24주 학습 구간을 요구하며, 국가 prior 선택에는 최소 2개 fold가 필요합니다. 따라서 보통 타깃 국가에 최소 48개 유효 주가 있어야 하고 3개 fold가 더 안정적입니다. 36~47주는 한 fold만 만들어지므로 후보 점수가 좋아 보여도 base를 유지합니다. 실제 spend·0/1 이벤트·구조변화 등 타깃 국가 설명변수는 실제값을 넣고 KPI만 가린 상태에서 모든 후보를 동일 folds로 비교합니다.

후보 검증에서는 모든 folds 중 가장 이른 학습 cutoff에서 타깃 Y 평균과 대표 $\alpha \cdot \text{ec} \cdot \text{slope}$ 를 한 번 고정합니다. 참고국 행도 그 cutoff까지 실제로 존재한 것만 사용하며, 이후 참고국 데이터나 가린 타깃 Y를 후보 prior에 넣지 않습니다. 국가별 spend 규모가 다르므로 각 채널의 양수 adstock 중앙값을 earliest-cut 타깃 운용 규모에 맞추는 배율을 적용한 뒤 같은 ec/Hill 단위로 참고국을 적합합니다. 날짜 정렬·변환·spend scale 중 하나라도 실패하면 그 국가는 보류됩니다. 조합을 선택한 뒤에만 선택국을 타깃 종료 주차까지의 참고기간과 전체 타깃 transform/Y scale로 재적합하며, 타깃 종료 뒤의 참고국 행은 사용하지 않습니다. 이 최종 수치에는 별도 독립 OOS가 없습니다.

```
spend_scale[m,c] = median_positive_adstock_target[m] / median_positive_adstock_reference[m,c]
eligibility requires finite RMSE on every common fold
mean_RMSE = mean(RMSE across all common folds)
score = (mean_RMSE + 0.25 * sd_RMSE)
* (1 + 0.025 * max(0, number_of_countries - 1))
```

9.4 국가 간 전달 이질성

참고 국가가 여러 개면 random-effects 방식으로 국가 간 평균 차이 τ^2 를 추정하고 새 타깃 시장을 위한 predictive prior를 만듭니다. 한 국가만 있을 때는 이질성을 추정할 수 없으므로 posterior SD가 아무리 작아도 상대 SD 하한을 50%로 둡니다. 여러 국가이면 상대 SD 하한은 25%이며, τ^2 와 within-country precision floor를 함께 적용합니다.


```

relative_floor = 0.50 if K = 1, else 0.25
relative_var_floor = (relative_floor * max(|pooled_mean|, sqrt(median(within_var))))^2
precision_floor_var = median(within_var) / max_effective_countries (max = 3)
predictive_var = tau^2 + max(pooled_mean_var, precision_floor_var, relative_var_floor)
transfer_precision = 1 / predictive_var

```

47개를 넣었다고 47개를 쓰지 않음

후보가 많아도 타깃 예측을 안정적으로 개선하는 소수 근거만 남깁니다. 국가 수가 늘어날수록 자동으로 좋게 평가되지 않으며, 복잡도 패널티와 국가 간 이질성이 prior 과신을 억제합니다.

9.5 올바른 해석

국가 rolling folds는 country-only prior가 base보다 가린 12주를 반복해서 개선하는지 보는 후보 tuning 자료입니다. 가장 이른 cutoff의 타깃 변환·Y scale·참고국 근거를 고정하므로 그 이후 정보 누수는 막지만, 같은 folds를 국가 shortlist와 조합 선택에 재사용합니다. 따라서 국가 prior가 선택되면 이를 독립 OOS 성능으로 다시 부르지 않으며 내부 OOS 표시는 비활성화합니다. 선택 후 타깃 종료일까지의 참고국·전체 타깃기간 재적합에서만 국가 prior를 만들고 별도 설계에서 추정된 실험 prior와 precision으로 결합합니다. 실험과 MMM이 같은 KPI 원자료를 공유했다면 실험 진단에 표시된 중복 사용 경계도 함께 적용합니다. 예측 개선도 인과 전달의 증명은 아닙니다.

10. 검증과 모델 건강지표

10.1 세 층의 검증

층	질문	주요 지표
적합	관측 기간을 얼마나 설명하는가?	R2, RMSE, wMAPE
예측	가린 미래 구간을 얼마나 맞추는가?	외부 prior 없는 base의 최근 20% OOS, 국가 12주 earliest-cut as-of tuning
식별·건강	틀린 이유로 맞춘 흔적은 없는가?	90% coverage, 잔차 ACF1, 음수 자연수요, prior shift

10.2 일반 OOS backtest

48주 이상이고 외부 prior가 없을 때만 마지막 20%를 학습에서 제외한 base OOS를 표시합니다. 학습 구간 안에서 변환 파라미터를 다시 선택하고 holdout 기간의 실제 매체비로 순방향 예측합니다. 외부 prior가 켜지면 이 base-only 점수를 prior 모델의 독립 점수로 오해하지 않도록 내부 OOS를 비활성화합니다. 실험 prior는 자체 효과 CI-Fieller-HAC/cluster-jackknife 진단으로, 국가 prior는 earliest-cut 타깃 변환/Y/참고국 근거에 고정한 country-only 대 base rolling 12주 후보 tuning으로 평가합니다. 최종 전체기간 적합에서만 두 근거를 precision 결합합니다.

10.3 건강지표 읽기

지표	의미	점검 신호	다음 행동
wMAPE	절대오차/실제 절대합	기본 모델 대비 악화	이벤트·구조변화·변환·prior 재검토
90% coverage	실제가 예측 90% 구간 안인 비율	너무 낮음 또는 거의 100%	구간 과소/과대 추정 점검
Residual ACF1	한 주 잔차와 다음 주 잔차의 상관	절대값 0.3 이상	추세·계절·잔효 누락 점검
Negative baseline	자연수요 추정이 0 미만인 주 비중	0보다 큼	모델 오지정·외삽 의심
Prior shift	posterior와 prior 평균 차이/prior SD	절대 2 이상	실험 전달성·데이터 충돌 검토
Top candidate weight	한 변환 후보에 쏠린 비중	너무 낮고 유효 후보 많음	변환 결론 불확실

10.4 예측 정확도와 인과 타당성은 다름

가격 변화 같은 미관측 교란요인이 입력되지 않은 채 R2가 높아도 매체 계수는 공선성과 누락 편향 때문에 틀릴 수 있습니다. 이 앱은 연속 가격 통제열을 직접 매핑하지 않으므로, 근거 있는 변화 시점만 0/1 이벤트·step으로 표현하고 나머지는 한계로 공개해야 합니다. 반대로 캠페인 변화가 드문 시장은 인과 효과가 있어도 채널별 추정 구간이 넓을 수 있습니다. 예측 검증, 식별 진단, 외부 실험을 함께 봐야 합니다.

R-hat 없음은 누락이 아니라 방법 차이

Meridian은 MCMC 체인의 수렴을 R-hat과 trace로 진단합니다. 이 앱은 해석적 posterior이므로 체인이 없고, 대신 예측·잔차·baseline·prior 충돌을 진단합니다.

11. 결과 화면 해석

11.1 기본 기여분해

주차별 stacked contribution은 대표 변환 후보 하나로 계산합니다. Trend는 절편을 포함한 자연수요 수준과 장기 방향을 함께 표시하며, Seasonality·Events·Regime change·Performance·Brand가 더해져 fitted KPI가 됩니다. residual은 실제와 fitted의 차이입니다.

```
actual[t] = sum(group_contribution[g,t]) + residual[t]
```

11.2 기여 크기 비중

드라이버 표의 비중은 각 그룹 주차별 기여의 제곱평균(RMS magnitude) 비중입니다. 변동을 크게 만든 그룹을 비교하는 진단값이며, 정확한 Shapley R2가 아닙니다. 총 기여량이나 증분 매출 비중으로 읽지 마세요.

```
magnitude[g] = mean(contribution[g,t]^2)
share[g] = magnitude[g] / sum_h magnitude[h]
```

11.3 채널 효과 카드

항목	해석
효과 평균	변환된 media feature 1단위가 KPI에 연결되는 평균 계수
90% 구간	prior 채널은 대표 변환 조건부 Gaussian; no-prior 채널은 mixture CDF 5%-95% 분위수
양수 확률	후보별 posterior 양수 확률의 BIC 가중 평균
후보 수	prior 채널은 단위 고정으로 1개, no-prior 채널은 적합에 성공한 profile 후보
유효 후보 수	가중치가 실제로 분산된 정도. 1에 가까우면 한 후보 우세
상위 후보 비중	가장 큰 BIC 가중치. 낮으면 변환 선택 불확실
현재 한계효과	원본 통화 기준 고정 증액 단위(KRW 100만·USD 1천)의 반응 변화와 90% 구간. 표시 통화 토글은 숫자 표기만 바꾸며 계산 단위를 바꾸지 않음

11.4 prior 토글

prior 있음/없음을 같은 KPI에서 즉시 비교합니다. 평균·90% 구간·양수 확률·prior shift가 어떻게 바뀌는지, 구간이 지나치게 좁아지지 않는지 봅니다. base OOS는 외부 prior가 없는 모델의 참고값일 뿐 prior 모델과 동등한 독립 비교로 부르지 않습니다. 실험은 자체 효과 CI와 식별 진단, 국가는 earliest-cut as-of rolling 후보 tuning을 별도 표기합니다. 결론이 prior 하나에 완전히 의존하면 그 사실 자체가 발표해야 할 민감도입니다.

점추정보다 범위

채널 A와 B의 현재 한계효과 90% 구간이 상위 채널 구간과 겹치면 앱은 한 채널을 1위로 확정하지 않고 후보 그룹으로 표시합니다. '둘 다 증액 후보지만 추가 실험으로 구분'처럼 액션을 범위로 표현합니다.

12. 반응곡선·예산 추천·미래예측

12.1 반응곡선

prior가 없는 채널 곡선은 profile 후보들의 BIC 가중 평균이고, prior 채널은 단위가 고정된 대표 변환 곡선입니다. x축은 지속 주간 spend, y축은 모델이 추정한 media response입니다. 최근 평균 spend와 비교해 포화와 한계효과를 확인합니다.

12.2 예산 추천

- 효과 구간이 넓거나 양수 확률이 낮은 채널은 큰 폭의 증액보다 측정 우선입니다.
- 한계효과 계산 단위는 원본 통화 기준 KRW 100만 또는 USD 1천으로 고정됩니다. 표시 통화 토글은 계산 단위를 바꾸지 않습니다.
- 증액 후 지속 spend를 profile 후보별 정상상태 adstock으로 바꿉니다. BIC 가중치 상위 누적 95% 후보 중 하나라도 과거 adstock 최대를 넘으면 외삽으로 표시하고 예산 추천에서 제외합니다.
- 상위 한계효과 90% 구간과 겹치는 채널은 후보 그룹으로 묶고 단일 순위를 만들지 않습니다.
- 브랜드·퍼포먼스의 KPI 지연 차이, 최소계약, 입찰 학습, 재고 제약은 모델 밖 제약으로 추가합니다.
- 예산 변경 후에는 새 데이터로 모델을 갱신하고, 가능하면 holdout으로 증분성을 확인합니다.

12.3 예산 액션 식별 게이트

아래 조건 중 하나라도 해당하면 앱은 방향 탐색 결과는 보여도 직접적인 증액·감액 추천을 차단합니다. 전체 모델 식별과 각 채널의 집행 이력·효과·현재 한계효과를 모두 통과해야 합니다.

게이트	차단 기준	의미
데이터 길이	52주 미만	앱 low-information 구간
관측/파라미터	주수 / 추정 파라미터 수 < 8	모델 자유도 대비 정보 부족
VIF	어느 매체 변수든 $VIF \geq 10$	다중 공선성으로 개별 효과 불안정
매체 관련 상관	매체-매체 또는 매체-비매체 설명변수 $ corr \geq 0.90$	채널별 예산 액션 분리 어려움
채널 활성 주	spend > 0인 주가 20주 미만	채널 자체 변동 근거 부족
채널 spend 변동	관측기간 spend가 상수	반응곡선·한계효과 식별 불가
최근 활성	최근 8주 모두 spend = 0	현재 예산 액션과 연결하기 어려움
효과 근거	해당 채널 $P(\text{effect} > 0) < 0.80$	증액을 지지할 확률 근거 부족
한계효과 구간	고정 증액 단위의 90% 구간 하한 ≤ 0	현재 증액의 양의 반응 불확실
변환 관측범위	증액 후 정상상태 adstock이 profile 상위 누적 95% 후보의 과거 adstock 최대를 넘음	flight형 채널 외삽도 표시하고 추천에서 제외

12.4 미래예측

미래 spend 시나리오에 adstock 상태를 순차적으로 넘겨 KPI를 예측합니다. 추세와 주기성 feature는 미래 주차에 맞게 전진시키고, 구조변화는 마지막 알려진 상태를 유지합니다. 미래 명절·이벤트는 알려진 경우 명시적으로 제공해야 하며, 모르면 0인 기준 시나리오로 해석합니다.

12.5 예측구간

예측구간은 잔차분산뿐 아니라 해당 미래 design row의 계수 불확실성 $x' \text{Cov}(\beta) x$ 를 포함합니다. 먼 미래·관측 범위 밖 입력에서는 구간과 모델 가정의 위험을 함께 보고해야 합니다.

```
predictive_var(x*) = sigma^2 * (1 + x*' (X'X + penalty)^-1 x*)
```

예측은 시나리오

계획 spend가 실제로 집행되고, 가격·제품·경쟁·측정체계가 모델 가정대로 유지된다는 조건부 결과입니다. 확정 매출 약속이 아닙니다.

13. KPI별 운영 방법

13.1 sticky 목표 전환

매핑된 KPI는 분석 화면의 sticky 선택기에 활성화됩니다. 목표를 바꾸면 같은 입력 구조를 유지하면서 해당 Y의 모델·prior·검증·반응곡선을 불러옵니다. KPI마다 계수 스케일과 식별성이 다르므로 한 목표의 결론을 다른 목표에 복사하지 않습니다.

13.2 퍼널 해석

목표	주요 질문	주의
총유입	상단 퍼널 볼륨을 누가 만들었나?	가입+재유입 합성 시 중복 여부 확인
가입	신규 획득에 어떤 채널이 연결되나?	중복가입·어트리뷰션 창 고정
재유입	기존 사용자 복귀에 어떤 채널이 연결되나?	리타게팅과 자연복귀 공선성
구매자	구매 사용자 수에 어떤 채널이 연결되나?	주간 unique 정의
매출	가치에 어떤 채널이 연결되나?	가격·환불 정의 고정; 프로모션은 정확한 0/1 이벤트로만 반영

13.3 KPI prior 적용표

prior 관리 화면에서 채널 x KPI 매핑 상태를 확인합니다. 예를 들어 실험 파일에 가입만 있고 MMM에 가입·재유입·매출이 있으면 가입 모델에만 실험 prior가 적용됩니다. 국가 prior도 동일합니다. 미매핑 목표는 'prior 없음'으로 명확히 표시합니다.

14. Google Meridian과의 비교

14.1 한눈에 보는 차이

항목	이 앱	Google Meridian
실행	브라우저 메모리, 서버 전송 없음	Python 패키지, 일반적으로 로컬/클라우드 연산
추론	σ^2 plug-in empirical-Bayes 조건부 Gaussian 근사	NUTS MCMC posterior sampling
공간 구조	타깃 1개 모델 + 선택적 국가 계수 prior	geo-level 계층형 random coefficients 또는 national 모델
매체 입력	주간 spend 기반 채널 feature	media execution과 spend, reach/frequency 지원
잔효·포화	기하 adstock + Hill; no-prior 채널 profile 평균, prior 채널 대표 변환 고정	HillAdstock, 설정 가능한 lag/adstock 구조
prior 종류	계수 Normal prior: 실험/국가 효과와 분산	ROI, mROI, contribution, coefficient priors 및 calibration
시간 baseline	선형 추세·Fourier 계절·이벤트·step	knot 기반 time-varying intercept와 controls
불확실성	σ^2 조건부 Gaussian + 채널별 profile mixture CDF	joint posterior samples로 전체 파라미터 불확실성
검증	base-only 20% OOS, 국가 12주 earliest-cut as-of tuning, 실험 Fieller/CI, fit/coverage/ACF/baseline/prior shift	holdout_id, model fit, posterior predictive 및 MCMC diagnostics
진단	R-hat/ESS/trace 해당 없음	R-hat, trace, ESS 등 sampling health
결정성	같은 입력은 같은 결과	seed:chain:sampling 변동 관리 필요
규모	마케터용 빠른 다중 KPI UX	GPU 권장 가능한 계산집약적 모델

14.2 일반적인 완전 Bayesian MMM과의 차이

항목	이 앱	완전 Bayesian MMM 계열
잔차분산	σ^2 plug-in 고정점 추정	σ^2 /오차분포에도 prior를 두고 적분 가능
비선형 파라미터	채널별 profile 후보 + BIC 가중	adstock·포화·계수를 joint posterior로 함께 추정 가능
계층 구조	국가 효과를 외부 prior로 전달	geo/채널 계수를 한 모델 안에서 partial pooling 가능
계산	결정론적 행렬 계산	MCMC·VI·SMC 등 확률 추론
진단	예측·잔차·식별·prior shift	위 항목 + chain 수렴·ESS·posterior predictive

따라서 이 앱을 단순히 'Bayesian이 아니다'라고 부르는 것도, Meridian과 같은 완전 Bayesian MMM이라고 부르는 것도 부정확합니다. 정확한 명칭은 Normal prior를 실제 분산으로 반영하는 empirical-Bayes 조건부 Gaussian 근사 MMM입니다.

14.3 반영한 Meridian 원칙

- 잔효와 포화를 분리해 매체 반응을 표현합니다.
- prior를 단순 가중치가 아니라 확률분포의 평균과 분산으로 다룹니다.
- 실험 근거의 point estimate와 standard error를 calibration 출발점으로 사용합니다.
- in-sample 적합도와 holdout 예측을 분리하고, prior-posterior 충돌과 baseline 이상을 확인합니다.

- 예측 정확도가 인과 타당성을 보장하지 않는다고 명시합니다.

14.4 현재 반영하지 않은 기능

기능	미반영 이유/영향	필요할 때
NUTS/MCMC	브라우저 계산·메모리·대기시간 부담. joint posterior 미제공	Python Meridian 또는 서버/로컬 분석환경
geo 계층형 random effects	국가 prior는 계수 전달이지 동일 모델의 partial pooling이 아님	충분한 geo 패널과 인구 데이터 확보
reach/frequency	현재 spend 열 중심	도달·빈도 품질이 높고 중복 정의 가능
ROI/mROI prior	현재 변환 feature 계수 단위 prior	비용·매출 단위와 ROI estimand를 엄격히 정렬
knot baseline	현재 추세/Fourier/step 구조	장기간 비선형 baseline과 충분한 데이터
joint transform averaging	채널별 profile 방식으로 계산량 제한	오프라인 MCMC/SMC 또는 제한된 후보 joint 탐색
posterior predictive sampling	조건부 정규 예측 참고구간 사용	비대칭·heavy-tail 불확실성이 중요할 때

어느 쪽이 더 좋은가

빠른 브라우저 분석·다중 KPI·민감 데이터 로컬 처리에는 이 앱이 유리합니다. geo partial pooling, reach/frequency, joint posterior, 표준 MCMC 진단이 핵심이면 Meridian이 더 적합합니다. 둘은 정확도 등급이 아니라 목적과 계산 구조가 다릅니다.

15. 정확도·인과·한계

15.1 가장 큰 오차 원인

원인	증상	대응
채널 공선성	구간 겹침·부호 불안정	채널 통합, 실험, 변동 구간 추가
누락된 교란요인	매체 효과 과대·잔차 자기상관	지원되는 프로모션·장애는 0/1 event/step으로 반영. 연속 가격·경쟁 변수는 직접 매핑되지 않으므로 기간 분리·외부 분석 또는 한계 공개
측정 정의 변경	step 시점 이후 residual 구조 변화	regime 열 추가, 기간 분리
prior 전달 실패	prior shift 쿼·국가 tuning 불안정	분산 확대 또는 prior 제거
짧은 데이터	후보 간 결론 분산	기간 확보, 후보 축소
범위 밖 예산	반응곡선 외삽	관측 범위 내 점진 변경

15.2 양수 확률의 언어

상태	권장 표현	금지 표현
높고 구간 양수	양의 효과를 지지하는 근거가 강함	확실히 인과효과가 있음
중간/구간 0 포함	방향은 양수이나 불확실, 실험 필요	효과 없음
낮거나 음수	이 데이터·가정에서 양의 효과 근거 부족	광고가 반드시 해로움
공선 경고	개별 채널 식별 불가	가장 나쁜 채널 확정

15.3 prior 선택 편향

많은 국가·조합을 시험한 뒤 가장 좋은 하나를 고르면 우연한 승자를 선택할 수 있습니다. 반복 fold, 불안정성 가산, 복잡도 패널티가 이를 줄이지만 완전히 제거하지는 않습니다. 최종 추천은 다음 기간이나 독립 실험에서 다시 확인합니다.

15.4 개인정보와 데이터 처리

CSV는 브라우저 메모리에서 처리되며 분석을 위해 서버로 전송하거나 저장하지 않습니다. 그래도 원본 파일에는 개인 식별정보를 넣지 말고, 국가·주차·채널 수준으로 집계한 데이터만 사용하세요.

16. 문제 해결

16.1 업로드와 매핑

증상	가능한 원인	해결
날짜가 주차로 안 묶임	날짜 형식 혼합·파싱 실패	YYYY-MM-DD로 통일
KPI가 활성화되지 않음	Y 열 미매핑·문자열 값	다섯 목표 중 해당 열을 다시 매핑
prior가 특정 Y에 없음	prior 파일에 같은 Y가 없음	정상 동작. 미매핑 Y는 기본 모델 사용
채널 prior가 안 붙음	헤더/매핑 이름 불일치	타겟과 prior의 채널 키를 동일하게 지정
국가가 섞임	country 열 없음/값 공란	모든 행에 일관된 국가 코드 입력

16.2 모델

증상	해석	조치
효과 구간이 매우 넓음	데이터 변동 부족·공선·후보 불확실	기간/실험 추가, 채널 통합
prior 후 구간이 지나치게 좁음	실험 CI 또는 전달분산 과소	정의 확인, 분산 확대/제거
R2 높지만 base OOS 나쁨	과적합·regime 변화	이벤트/step 재검토, 결론 하향
잔차 ACF 큼	시간 구조 누락	추세·계절·adstock 후보·이벤트 확인
음수 자연수요	baseline 오지정 또는 외삽	모델 결과를 의사결정에 사용 중지 후 재설계
상위 후보 비중 낮음	잔효/포화 식별 약함	곡선을 접이 아닌 범위로 사용

16.3 실험 prior

증상	확인 순서
On/Off 생성 실패	최소 16개 유효 주, ON-OFF 각각 4주, 상태 전환 2회, bounded Fieller, HAC:block jackknife 진단을 확인
Geo 생성 실패	최소 16개 geo-week·4개 geo-arm당 2개, 공통 pre/post·4개 셀, cluster-전 LOCO-bounded Fieller-타겟 H ₀ 미분 정렬을 확인
동일 KPI 재사용 보류	national On/Off KPI가 메인 MMM의 같은 주 Y와 정확히 일치하는지 확인하고 별도 실험 집계만 사용
SE가 매우 큼	실험 기간·geo 수·처리강도·동시 이벤트를 확인. 큰 SE는 약한 prior로 정상 반영
효과 부호가 예상과 반대	KPI 방향, state/arm/period 코딩, spend 단위, 시간 정렬을 재검토
Geo마다 값이 뒀	지역별 표본 크기와 pre-trend를 확인하고 cluster 수가 충분한지 점검

16.4 국가 prior

- 후보 0개: 겹치는 채널·KPI·기간·country 매핑을 확인합니다.
- 각 참고 국가에 최소 24개 유효 주간 행이 있는지 확인합니다.
- 모든 후보가 기본보다 나쁨: prior를 쓰지 않는 것이 올바른 결과입니다.

- 타깃이 36~47주라 fold가 1개뿐이면 선택하지 않고 base를 유지합니다. 최소 2개 fold(보통 48주), 가능하면 3개를 확보합니다.
- 10개 이상 추천되는 것처럼 보임: 실제 추천 조합과 개별 유의미 후보 목록을 구분합니다.
- fold별 승패가 바뀔: 평균만 보지 말고 sd와 복잡도 포함 score를 사용합니다.
- 국가 간 계수 차이가 큼: τ^2 가 precision을 낮추는 것이 정상입니다.

17. 발표·검토 체크리스트

17.1 데이터 승인

- 분석 국가, 기간, 주차 정의, 통화, KPI 정의와 전환창을 문서화했다.
- 일별→주간 집계 규칙과 이벤트 발생 여부 규칙을 확인했다.
- 누락·중복·부분 주·측정 변경을 검토했다.
- 지원되는 프로모션·명절·장애를 정확한 0/1 event/step으로 반영했다. 연속 가격·경쟁 변수는 직접 매핑되지 않는 한 계와 정의 변화를 공개했다.

17.2 모델 승인

- 기본 모델과 prior 모델을 모두 비교했다.
- 외부 prior 없는 base에서만 제공되는 OOS wMAPE와 coverage, residual ACF, negative baseline, prior shift를 확인했다.
- 후보 수·유효 후보 수·상위 후보 비중을 기록했다.
- 공선성과 구간 겹침이 큰 채널의 순위를 확정하지 않았다.
- 기여 크기 비중을 Shapley R2라고 부르지 않았다.

17.3 prior 승인

- 실험 설계·기간·KPI·처리강도·CI 계산법을 공개했다.
- 실험 KPI와 메인 MMM Y의 기간 중첩·정확 일치 진단을 확인하고, 동일 결과의 이중 사용이 없음을 확인했다.
- 국가 정의·통화·전환창 일치를 사람이 검증했다.
- 국가 12주 반복 fold와 복잡도 패널티 결과를 공개했다.
- 미매핑 Y에 prior가 적용되지 않았음을 확인했다.

17.4 발표 문구 템플릿

권장 문구

본 결과는 주간 관측 데이터에 광고 잔효·포화 후보와 정규 prior를 적용한 empirical-Bayes 조건부 Gaussian 근사 MMM입니다. 잔차분산은 plug-in 추정하며, 변환 불확실성은 채널별 profile BIC 평균으로 반영했습니다. 완전 계층형 joint MCMC 모델은 아닙니다. 채널별 수치는 인과 확정값이 아니라 실험·홀드아웃과 함께 사용하는 범위형 의사결정 근거입니다.

18. 용어집

용어	정의
Adstock	현재 집행과 과거 잔효를 합친 매체 상태
alpha	기하 adstock의 주간 잔존 비율
Hill	지출 증가에 따른 포화를 표현하는 S자/오목 반응함수
ec / half-saturation	Hill 반응이 절반에 도달하는 adstock 수준
slope	Hill 곡선의 굴곡·가파름
Prior	데이터 적합 전에 외부 근거로 둔 파라미터 분포
Posterior	관측 데이터와 prior를 결합한 뒤의 파라미터 분포
Precision	분산의 역수. 클수록 prior가 강함
90% interval	모델과 근사 아래 계수 불확실성을 나타내는 범위
Profile model	한 채널 후보만 바꿔 다시 적합한 비교 모델
BIC weight	적합도와 복잡도를 함께 반영한 후보 상대 가중치
Effective candidates	후보 가중치가 실제 몇 개에 분산됐는지 나타내는 역집중도
OOS	학습에 쓰지 않은 기간(out-of-sample)
wMAPE	절대오차 합을 실제값 절대합으로 나눈 비율
Coverage	실제가 예측구간 안에 들어온 비율
Residual ACF1	인접 주 잔차의 자기상관
DiD	처리/통제의 pre-post 차이를 다시 비교하는 차이의 차이
HAC SE	시계열 자기상관·이분산에 견고한 표준오차
Cluster-robust SE	같은 geo 내 오차 상관을 허용하는 표준오차
Jackknife	일부 블록을 순차 제외해 추정 불안정성을 재는 방법
τ^2	참고 국가 간 전달 계수의 이질성 분산
Ridge	계수 과대화를 줄이는 L2 정규화
R-hat	MCMC 체인 수렴 지표. 이 앱에는 체인이 없어 해당 없음
Shapley R2	변수 그룹의 설명력 기여를 순열로 배분한 값. 현재 MMM 비중표는 이것이 아님
Incrementality	광고가 없었을 반사실 대비 순증분 효과

부록 A. 계산·화면 대응표

화면 요소	계산 원천	검토 질문
주차별 기여	대표 변환 + posterior 평균 계수	대표 후보 의존성을 공개했나?
효과 90% 구간	prior 채널 조건부 Gaussian / no-prior profile mixture CDF 분위 수	0 포함과 후보 분산을 확인했나?
양수 확률	후보별 Gaussian 확률의 BIC 평균	인과 확률로 과장하지 않았나?
반응곡선	정상상태 adstock의 후보 가중 반응	관측 spend 범위 안인가?
기여 크기 비중	$\text{mean}(\text{contribution}^2)$ 정규화	Shapley R2라고 쓰지 않았나?
실험 prior	효과/노출 contrast 비율 + 보수적 variance	실험 전달성이 맞나?
국가 prior	국가 계수 + τ^2 + rolling 선택	후보 선택 편향을 공개했나?
미래예측	미래 feature + posterior predictive variance	이벤트·regime 가정을 썼나?

부록 B. 공식 참고자료

아래 링크는 비교 기준으로 사용한 Google의 공식 문서와 공식 저장소입니다. Meridian 기능은 버전에 따라 바뀔 수 있으므로 실제 도입 시 최신 문서를 다시 확인하세요.

[Google Meridian - Model specification](https://developers.google.com/meridian/docs/advanced-modeling/model-spec)

<https://developers.google.com/meridian/docs/advanced-modeling/model-spec>

[Google Meridian - ModelSpec API](https://developers.google.com/meridian/reference/api/meridian/model/spec/ModelSpec)

<https://developers.google.com/meridian/reference/api/meridian/model/spec/ModelSpec>

[Google Meridian - ROI priors and calibration](https://developers.google.com/meridian/docs/advanced-modeling/roi-priors-and-calibration)

<https://developers.google.com/meridian/docs/advanced-modeling/roi-priors-and-calibration>

[Google Meridian - Choosing treatment prior types](https://developers.google.com/meridian/docs/advanced-modeling/how-to-choose-treatment-prior-types)

<https://developers.google.com/meridian/docs/advanced-modeling/how-to-choose-treatment-prior-types>

[Google Meridian - Collect data](https://developers.google.com/meridian/docs/pre-modeling/collect-data)

<https://developers.google.com/meridian/docs/pre-modeling/collect-data>

[Google Meridian - Geo selection and national data](https://developers.google.com/meridian/docs/pre-modeling/geo-selection-national-data)

<https://developers.google.com/meridian/docs/pre-modeling/geo-selection-national-data>

[Google Meridian - Model health checks](https://developers.google.com/meridian/docs/post-modeling/health-checks)

<https://developers.google.com/meridian/docs/post-modeling/health-checks>

[Google Meridian - Model fit](https://developers.google.com/meridian/docs/post-modeling/model-fit)

<https://developers.google.com/meridian/docs/post-modeling/model-fit>

[Google Meridian - Model diagnostics](https://developers.google.com/meridian/docs/user-guide/model-diagnostics)

<https://developers.google.com/meridian/docs/user-guide/model-diagnostics>

[Google Meridian - Interpret visualizations](https://developers.google.com/meridian/docs/post-modeling/interpret-visualizations)

<https://developers.google.com/meridian/docs/post-modeling/interpret-visualizations>

[Google Meridian source repository](https://github.com/google/meridian)

<https://github.com/google/meridian>

문서 버전 메모

이 설명서는 MMM methodology 1.1.0의 empirical-Bayes 조건부 Gaussian 근사, 채널별 profile 모델 평균, 실험/국가 prior, 반복 검증, 건강지표를 기준으로 작성되었습니다. 화면의 모델 버전과 설명서 발행일을 함께 보관하세요.